

Сравнение эффективности алгоритмов SVD и QR with column pivoting для определения ранга матрицы

команда “Миньоны Тыртыша”

Оганов А. А.

Никишкин П. Г.

Давыдов К. Е.

Математическая постановка задачи

Опр 1. Факторизация, раскрывающая ранг (RRF)

$$A \in \mathbf{R}^{m \times n}, X \in \mathbf{R}^{m \times p}, D \in \mathbf{R}^{p \times p}, Y \in \mathbf{R}^{p \times n}, p \leq \min(m, n)$$

$A = XDY$, где D - диагональная, а X, Y - хорошо обусловленные

Примеры: SVD, QR разложение с поворотом столбцов

QR разложение с поворотом столбцов

$AP = QR$, где P — матрица перестановок, $Q \in \mathbf{R}^{m \times n}$ имеет ортонормированные столбцы, $R \in \mathbf{R}^{n \times n}$ является верхнетреугольной и удовлетворяет неравенствам:

$$|r_{kk}|^2 \geq \sum_{i=k}^j |r_{ij}|^2, j = k + 1 : n, k = 1 : n, \quad |r_{11}| \geq |r_{22}| \geq \dots \geq |r_{nn}|$$

Постановка задачи

Сравнение методов оценки ранга матриц с помощью SVD и QR разложений.

Критерии сравнения:

1. Вычислительная сложность
2. Точность получаемых результатов
3. Поведение алгоритмов на реальных данных

Реализации:

QR - `scipy.linalg.qr(pivoting=True)`

SVD - `np.linalg.svd()`

Что такое rank?


Будем использовать следующее определение ранга матрицы:

$$\text{rank}(A) = k \iff \|A - B\|_F \leq \varepsilon \|A\|_F$$


Матрица B определяется для каждого метода по своему. В случае QR мы оставляем первые k строк треугольной матрицы, в случае SVD - первые k сингулярных чисел.

Зависимость времени от размерности матрицы


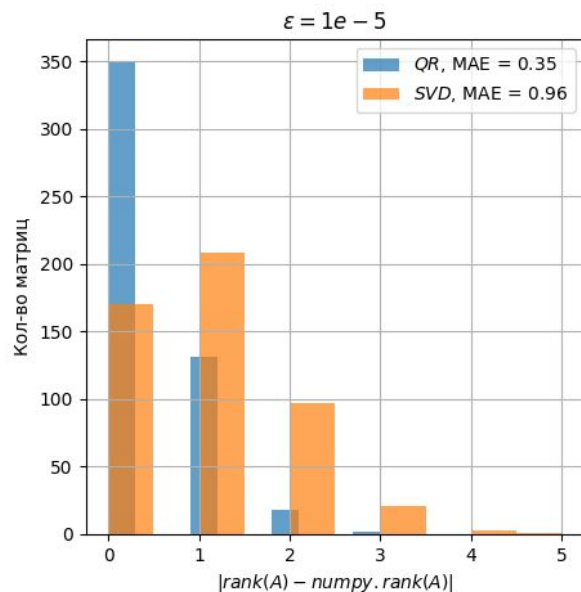

QR






SVD



Точность оценки в сравнении с numpy



Корректность определения ранга



Промежуточные выводы

1. QR разложение работает быстрее SVD, что более заметно при увеличении размерности матрицы
2. При сравнении с numpy QR имеет меньше ошибку, чем SVD
3. Оба алгоритма и numpy считают число, которое похоже на истинное значение ранга
4. При использовании SVD получаются меньшие значения ранга

Ранг изображения

rank = 512
 $\|A - B\|_F = 0 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.000$



rank = 64
 $\|A - B\|_F = 360 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.002$



rank = 32
 $\|A - B\|_F = 1155 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.005$



rank = 16
 $\|A - B\|_F = 3034 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.013$



SVD
 $\|A - B\|_F = 0 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.000$



$\|A - B\|_F = 150 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.001$



$\|A - B\|_F = 477 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.002$



$\|A - B\|_F = 1313 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.006$



QR


$$\text{rank} = 512$$

$$\|A - B\|_F = 0 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.000$$



$$\text{rank} = 64$$

$$\|A - B\|_F = 124 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.001$$



$$\text{rank} = 32$$

$$\|A - B\|_F = 558 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.003$$



$$\text{rank} = 16$$

$$\|A - B\|_F = 1643 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.008$$




SVD


$$\|A - B\|_F = 0 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.000$$



$$\|A - B\|_F = 54 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.000$$



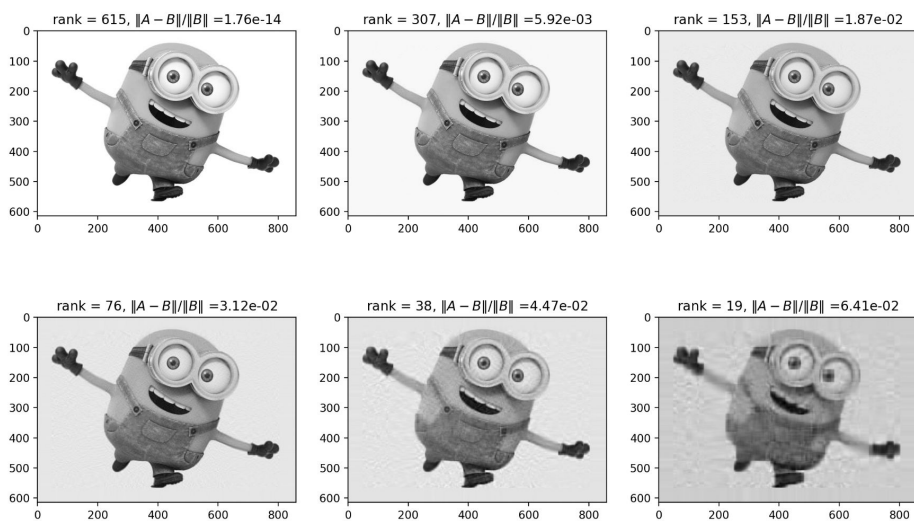
$$\|A - B\|_F = 263 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.001$$



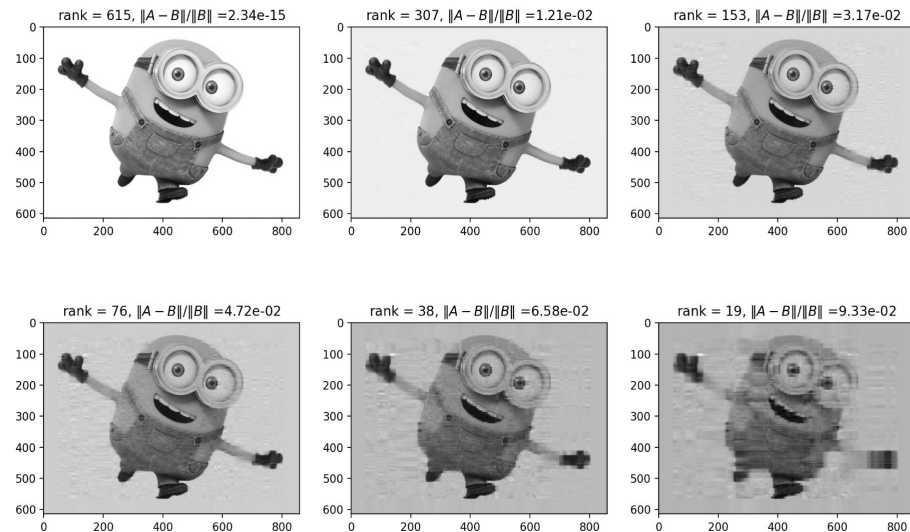
$$\|A - B\|_F = 908 \quad \frac{\|A - B\|_F}{\|A\|_F} = 0.004$$



Результаты сжатия черно-белого изображения



с помощью SVD



с помощью QR

Промежуточные выводы

1. При помощи SVD можно приблизить матрицу малоранговой более точно (как по норме, так и визуально), чем при QR.
2. Несмотря на то, что `numpy` оценивает изображение как полноранговую матрицу, ее можно представить как матрицу с меньшим рангом без потери визуального качества.

Выводы

1. Было обнаружено существенное превосходство QR над SVD по времени работы на матрицах больших размеров, а также по точности определения ранга в сравнении с методом из библиотеки numru. Однако SVD показывает лучший результат для малорангового приближения матрицы: сжатие получается более точным и визуально, и по значению ошибки.
2. Полученные выводы соответствуют высказанным заранее предположениям об эффективности работы алгоритмов.
3. Среди возможных путей дальнейшего развития проекта можно рассмотреть другие факторизации, раскрывающие ранг (LU, UTV), и сравнить их эффективность

Что хотелось бы проверить?

1. Другой домен данных для плотных матриц, например, речь, аудио, различные сигналы
2. Проверить качество и время на случайных разреженных матрицах
3. Проверить QR для получения малорангового приближения матриц рекомендательных систем

ОСНОВНЫЕ ССЫЛКИ

1. [“What Is a Rank-Revealing Factorization?”](#), May 19, 2021 by Nick Higham
2. Golub, Gene H., and Charles F. Van Loan. *Matrix Computations*. 4th ed. Baltimore, MD: Johns Hopkins University Press, 2013, Sections 5.4.*
3. [Project on GitHub](#)